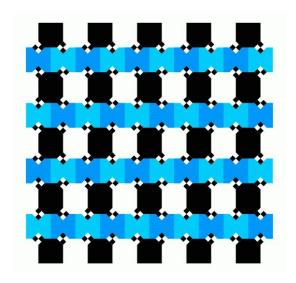
# Introduzione alla Programmazione Parallela

Ultimo aggiornamento: 6 gennaio 2016



#### **Camil Demetrescu**

Dipartimento di Ingegneria Informatica, Automatica e Gestionale "A. Ruberti" Sapienza Università di Roma

# Indice

#### 2 Vettorizzazione

- 2.1 Compilazione di programmi che usano estensioni vettoriali
- 2.2 Tipi vettoriali
- 2.3 Istruzioni per leggere e scrivere su oggetti vettoriali
  - 2.3.2 Copia da memoria a vettore (load)
  - 2.3.3 Copia da vettore a memoria (store)
- 2.4 Operazioni aritmetiche
  - 2.4.1 Addizione e sottrazione
  - 2.4.2 Moltiplicazione
  - 2.4.2 Minimo e massimo
- 2.5 Esempi
  - 2.5.1 Somma vettoriale di array di dimensione arbitraria
  - 2.5.2 Prodotto scalare di array di dimensione arbitraria

# **Bibliografia**

## 2 Vettorizzazione

La **vettorizzazione** è una classica forma di parallelismo SIMD a livello di istruzione. Consente di effettuare operazioni supportate nativamente dall'hardware su piccoli vettori di numeri. Ad esempio, con una singola istruzione macchina è possibile sommare due vettori di 32 char, 16 short, o 8 int. La vettorizzazione può essere effettuata **manualmente dal programmatore**, ma **spesso sono i compilatori a farlo in automatico**, generando codice assembly che usa istruzioni vettoriali. Ad esempio, molte funzioni della libreria C, come quelle di manipolazione delle stringhe, sono compilate in forma vettorizzata.

Le CPU moderne sono equipaggiate con **estensioni** che forniscono un ampio set di **registri e istruzioni macchina vettoriali**, originariamente introdotti per supportare lo sviluppo di applicazioni multimediali. In particolare, le architetture x86 hanno una lunga storia di estensioni successive, ognuna delle quali estende le precedenti con nuove funzionalità: MMX (1996), 3DNow! (1998), SSE (1999), SSE2 (2001), SSE3 (2004), SSSE3 (2006), SSE4 (2006), AVX (2008), AVX2 (2012), AXV-512 (2015).

Per svincolare il programmatore dal dover sviluppare direttamente in assembly le applicazioni che usano estensioni vettoriali, i compilatori forniscono una batteria di **intrinsic**, cioè particolari costrutti di alto livello (come tipi e funzioni C) che vengono tradotti direttamente in termini di costrutti dell'instruction set architecture (ISA) della macchina soggiacente.

**Esempio 1.** Per sommare due vettori a e b di 4 int usando intrinsic SSE2 basta semplicemente scrivere c = \_mm\_add\_epi32(a,b), dove a, b e c sono variabili del tipo vettoriale \_\_m128i. La chiamata \_mm\_add\_epi32 viene tradotta nell'istruzione macchina paddd. L'esempio seguente mostra come leggere, scrivere ed effettuare operazioni su variabili vettoriali:

```
somma(A,B,C);
printf("%d %d %d\n", C[0], C[1], C[2], C[3]); // stampa 5 5 5 5
return 0;
}
```

Si noti l'uso degli intrinsic load e store per trasferire dati da memoria a variabile vettoriale e viceversa. Vedremo le istruzioni più in dettaglio nel seguito. In questa dispensa analizzeremo gli intrinsic più frequentemente usati, per una trattazione più completa si rimanda al sito Web [IntelIntr], che fornisce una documentazione dettagliata degli intrinsic della famiglia x86.

## 2.1 Compilazione di programmi che usano estensioni vettoriali

In questa dispensa assumiamo di usare una piattaforma equipaggiata con compilatore gcc. Per compilare un programma che usa estensioni vettoriali, includeremo la header immintrin.h che rende visibili gli intrinsic e aggiungeremo alla riga di comando gcc un'opzione per abilitare il supporto alla vettorizzazione. Se x è il nome dell'estensione da usare, l'opzione da usare è -mx. Ad esempio, per usare AVX2 scriveremo -mavx2. Si noti che ogni opzione include tutte quelle precedenti. Ad esempio, usando -msse2 si possono usare tutte le funzionalità offerte da SSE e SSE2.

**Esempio 2.** Il programma dell'esempio 1 può essere compilato con gcc -msse2 vecsum.c -02 -o vecsum ed eseguito con ./vecsum.

Compilando il programma con gcc -msse2 vecsum.c -02 -s, si ottiene il seguente codice x86-64 per la funzione somma<sup>1</sup>:

```
somma:
    movdqa (%rdi), %xmm0  # <-- _mm_load_si128
    paddd (%rsi), %xmm0  # <-- _mm_add_epi32
    movdqa %xmm0, (%rdx)  # <-- _mm_store_si128
    ret</pre>
```

Si noti come gli intrinsic si mappino su istruzioni macchina e registri (xmm0 nell'esempio).

# 2.2 Tipi vettoriali

I **tipi vettoriali** descrivono oggetti vettoriali che possono essere tenuti in particolari registri della CPU. I tipi vettoriali vengono anche chiamati **packed data type**, poiché consentono di impaccare più valori scalari dello stesso tipo in un unico oggetto. I tipi principali sono:

<sup>&</sup>lt;sup>1</sup> Si noti che, secondo le convenzioni AMD64 ABI, i primi tre parametri della funzione somma (indirizzi degli array A, B, C) sono passati nei registri rdi, rsi e rdx, rispettivamente.

|        | Tipo               |                      |            |                        | Estensione        |
|--------|--------------------|----------------------|------------|------------------------|-------------------|
| Intero | Precisione singola | Precisione<br>doppia | Dimensione | Registri usati         | vettoriale<br>x86 |
| m64    |                    |                      | 8 byte     | 8 (MM0-MM7)            | MMX               |
| m128i  | m128               | m128d                | 16 byte    | 16 (XMM0-XMM15)        | SSE               |
| m256i  | m256               | m256d                | 32 byte    | <b>16</b> (YMM0-YMM15) | AVX               |
| m512i  | m512               | m512d                | 64 byte    | <b>32</b> (ZMM0-ZMM31) | AVX-512           |

La loro capienza in termini vettoriali è come segue:

| Intero | Capienza |           |         | Precis.<br>singola | Capienza  | Precis.<br>doppia | Capienza  |
|--------|----------|-----------|---------|--------------------|-----------|-------------------|-----------|
| m64    | char[8]  | short[4]  | int[2]  |                    |           |                   |           |
| m128i  | char[16] | short[8]  | int[4]  | m128               | float[4]  | m128d             | double[2] |
| m256i  | char[32] | short[16] | int[8]  | m256               | float[8]  | m256d             | double[4] |
| m512i  | char[64] | short[32] | int[16] | m512               | float[16] | m512d             | double[8] |

Si noti che i tipi a 512 bit non sono ancora supportati, ma è previsto il loro inserimento nell'architettura Knights Landing di Intel nel 2016. Tecnicamente, i tipi vettoriali sono struct C. E' quindi possibile assegnare un oggetto vettoriale ad un altro mediante l'operatore di assegnamento =.

#### Esempio.

```
__m128i a = ...;
__m128i b = a;  // ok, è possibile assegnare un oggetto vett. a un altro
```

Inoltre, passare un oggetto vettoriale come **parametro a una funzione** implica passare una copia dell'intero oggetto, e non del solo indirizzo come avverrebbe passando un array come parametro.

# 2.3 Istruzioni per leggere e scrivere su oggetti vettoriali

Per poter effettuare un calcolo vettoriare è innanzitutto necessario caricare l'input in opportuni oggetti vettoriali. Allo stesso modo, è necessario poter estrarre il risultato dagli oggetti vettoriali che sono il risultato del calcolo.

#### 2.3.1 Allineamento in memoria

Le estensioni vettoriali forniscono istruzioni che permettono di trasferire dati da memoria a oggetto vettoriale, e viceversa. Ci sono **due versioni** di queste istruzioni: quelle che richiedono che l'indirizzo di memoria acceduto sia **allineato** a un multiplo della dimensione dell'oggetto vettoriale copiato, e quelle che possono accedere a **qualsiasi indirizzo anche non allineato**. Le versioni allineate garantiscono prestazioni migliori. Se si passa un indirizzo non allineato a una funzione che richiede allineamento, potrebbe generarsi un errore di accesso alla memoria durante l'esecuzione (**segmentation fault**, o general-protection exception).

#### Allineamento di variabili.

Il compilatore gcc fornisce supporto per dichiarare variabili allineate a indirizzi multipli di una costante n usando la direttiva  $_attribute_((aligned(n)))$ .

**Esempio.** La seguente dichiarazione introduce un array di interi allineato a 16 byte:

```
int v[4] __attribute__((aligned(16))) = { 3, 5, 7, 1 };
```

#### Allineamento di blocchi allocati dinamicamente.

La funzione malloc potrebbe non garantire il corretto allineamento di oggetti vettoriali come quelli a 256 bit. Per allocare dinamicamente blocchi con l'allineamento desiderato è possibile usare la funzione posix\_memalign definita dallo standard POSIX 1003.1d [PosixMemalign], oppure funzioni come memalign o valloc fornite dalla GNU standard library (che potrebbero non essere tuttavia disponibili su tutte le piattaforme) [GNUMemalign].

#### 2.3.2 Copia da memoria a vettore (load)

Queste operazioni consentono di copiare dati da memoria a oggetto vettoriale.

|             | _load_si128 (m128i con<br>_loadu_si128(m128i con  | <del>_</del> | array interi all. →m128i<br>array interi →m128i |  |
|-------------|---|--------------|---|--|
| Opzione gcc | -msse2  | Istruzione   | movdqa xmm, m128<br>movdqu xmm, m128            |  |
| Descrizione | Restituisce oggettom128i inizializzato con i 16 byte di dati interi (array di char, short, int, long, con o senza segno) presi dall'indirizzo di memoria mem_addr. La versione _mm_load_si128 richiede che mem_addr sia allineato a un multiplo di 16 byte. |              |   |  |
| Esempio     | <pre>int va[4]attribute((aligned(16))) = { 3, 5, 7, 1 };m128i a = _mm_load_si128((m128i const*)va);</pre>   |              |   |  |
| Zoompio     | <pre>int vu[4] = { 3, 5, 7, 1 };m128i b = _mm_loadu_si128((m128i const*)vu);</pre>  |              |   |  |

|             | 256_load_si256 (m256i<br>256_loadu_si256(m256i   |            | array interi all. →m256i<br>array interi →m256i |  |
|-------------|--|------------|---|--|
| Opzione gcc | -mavx  | Istruzione | vmovdqa ymm, m256<br>vmovdqu ymm, m256          |  |
| Descrizione | Restituisce oggettom256i inizializzato con i 32 byte di dati interi (array di char, short, int, long, con o senza segno) presi dall'indirizzo di memoria mem_addr. La versione _mm256_load_si256 richiede che mem_addr sia allineato a un multiplo di 32 byte. |            |   |  |
| Esempio     | <pre>int va[8]attribute((aligned(32))) = { 3, 5, 7, 1, 3, 2, 6, 1 };m256i a = _mm256_load_si256((m256i const*)va);</pre>   |            |   |  |
| Lacinpio    | <pre>int vu[8] = { 3, 5, 7, 1, 3, 2, 6, 1 };m256i b =mm256_loadu_si256((m256i const*)vu);</pre>  |            |   |  |

Si noti che le stesse istruzioni possono essere usate per trasferire array di tipi interi diversi. Per questo motivo, è richiesto un cast dell'indirizzo (es. ( m256i const\*) v).

| m128 _mm_load_ps (float const* mem_addr) |   |            |                                   |  |
|--|---|------------|-----------------------------------|--|
| Opzione gcc                              | -msse   | Istruzione | movaps xmm, m128 movups xmm, m128 |  |
| Descrizione                              | Restituisce oggettom128 inizializzato con l'array di 4 float all'indirizzo di memoria mem_addr. La versione _mm_load_ps richiede che mem_addr sia allineato a un multiplo di 16 byte. |            |                                   |  |
| Esempio                                  | float va[4]attribute((aligned(16))) = { 3.1, 5.3, 7.9, 1 };<br>m128 a = _mm_load_ps(va);  |            |                                   |  |
| 200pio                                   | float vu[4] = { 3.1, 5.<br>_m128 b = _mm_loadu_ps   |            |                                   |  |

| m128d _mm_load_pd (double const* mem_addr) double[2] all. →m128d _mm_loadu_pd (double const* mem_addr) double[2] →m128d |   |            |                                   |  |
|---|---|------------|-----------------------------------|--|
| Opzione gcc   | -msse2  | Istruzione | movapd xmm, m128 movupd xmm, m128 |  |
| Descrizione   | Restituisce oggettom128d inizializzato con l'array di 2 double all'indirizzo di memoria mem_addr. La versione _mm_load_pd richiede che mem_addr sia allineato a un multiplo di 16 byte. |            |                                   |  |
| Esempio   | <pre>double va[2]attribute((aligned(16))) = { 3.1, 5.3 };m128d a = _mm_load_pd(va);</pre>   |            |                                   |  |
|   | double vu[2] = { 3.1, 5   | .3 };      |                                   |  |

```
__m128d b = _mm_loadu_pd(vu);
```

|             | 56_load_ps (float const*<br>56_loadu_ps(float const*   | <del>_</del> | float[8] <b>all</b> . $\rightarrow$ m256 float[8] $\rightarrow$ m256 |  |
|-------------|--|--------------|--|--|
| Opzione gcc | -mavx  | Istruzione   | vmovaps ymm, m256<br>vmovups ymm, m256                               |  |
| Descrizione | Restituisce oggettom256 inizializzato con l'array di 8 float all'indirizzo di memoria mem_addr. La versione _mm256_load_ps richiede che mem_addr sia allineato a un multiplo di 32 byte. |              |  |  |
| Esempio     | float va[8]attribute((aligned(32))) = { 3.1, 5.3, 7.9, 1, 3.1, 5.3, 7.9, 1 };  m256 a = mm256 load ps(ya);   |              |  |  |

| Opzione gcc | -mavx  | Istruzione | vmovapd ymm, m256<br>vmovupd ymm, m256 |  |
|-------------|--|------------|--|--|
| Descrizione | Restituisce oggettom256d inizializzato con l'array di 4 double all'indirizzo di memoria mem_addr. La versione _mm256_load_pd richiede che mem_addr sia allineato a un multiplo di 32 byte. |            |  |  |
| Esempio     | <pre>double va[4]attribute((aligned(32))) = { 3.1, 5.3, 7.9, 1 };m256d a = _mm256_load_pd(va);</pre>   |            |  |  |
| 200111010   | double vu[4] = { 3.1, 5<br>_m256d b = _mm256_load  |            |  |  |

# 2.3.3 Copia da vettore a memoria (store)

Queste operazioni consentono di copiare dati da un oggetto vettoriale a memoria. Come per la load, ci sono due versioni, a seconda che l'indirizzo destinazione sia allineato o meno.

|             | ore_si128 (m128i* mem_<br>oreu_si128(m128i* mem_  | <del></del> | m128i → array interi all.<br>m128i → array interi |
|-------------|---|-------------|---|
| Opzione gcc | -msse2  | Istruzione  | movdqa m128, xmm<br>movdqu m128, xmm              |
| Descrizione | escrizione Copia l'oggetto a nei 16 byte di dati interi (array di char, short, int, long, con o senza |             |   |

```
segno) all'indirizzo di memoria mem_addr. La versione _mm_store_si128 richiede che
mem_addr sia allineato a un multiplo di 16 byte.

__m128i a = _mm_set_epi32(2, 5, 3, 1);
int va[4] __attribute__((aligned(16)));
_mm_store_si128((__m128i*)va, a);

__m128i b = _mm_set_epi32(2, 5, 3, 1);
int vu[4];
_mm_storeu_si128((__m128i*)vu, b);
```

```
void _mm256_store_si256 ( m256i* mem addr, m256i a)
                                                                  m256i \rightarrow array interi all.
                                                                  m256i → array interi
void _mm256_storeu_si256( m256i* mem addr, m256i a)
                                                                  vmovdga m256, ymm
Opzione gcc
                                       Istruzione
            -msse2
                                                                  vmovdqu m256, ymm
             Copia l'oggetto a nei 32 byte di dati interi (array di char, short, int, long, con o senza
Descrizione
             segno) all'indirizzo di memoria mem addr. La versione mm store si128 richiede che
             mem addr sia allineato a un multiplo di 32 byte.
              m256i a = mm256 set epi32(2, 5, 3, 1, 7, 9, 4, 6);
             int va[8] attribute ((aligned(32)));
             mm256 store si256(( m256i*)va, a);
Esempio
              m256i b = mm256 set epi32(2, 5, 3, 1, 7, 9, 4, 6);
             int vu[8];
             mm256 storeu si256(( m256i*)vu, b);
```

```
m128 \rightarrow float[4] all.
m128 \rightarrow float[4]
                                                        movaps m128, xmm
                                 Istruzione
Opzione gcc
           -msse
                                                        movups m128, xmm
           Copia l'oggetto a nell'array di 4 float all'indirizzo di memoria mem addr. La versione
Descrizione
           mm store ps richiede che mem addr sia allineato a un multiplo di 16 byte.
            m128 a = mm set ps(2.1, 5.2, 3.1, 1.9);
           float va[4] attribute ((aligned(16)));
           mm store ps(va, a);
Esempio
            m128 b = mm set ps(2.1, 5.2, 3.1, 1.9);
           float vu[4];
           mm storeu ps(vu, b);
```

```
void mm256_store_ps (float* mem_addr, __m256 a)
                                                              m256 \rightarrow float[8] all.
m256 \rightarrow float[8]
                                                             vmovaps m256, ymm
Opzione gcc
                                    Istruzione
           -mavx
                                                             vmovups m256, ymm
            Copia l'oggetto a nell'array di 8 float all'indirizzo di memoria mem addr. La versione
Descrizione
            mm256 store ps richiede che mem addr sia allineato a un multiplo di 32 byte.
             m256 a = mm256 set ps(2.1, 5.2, 3.1, 1.9, 7.3, 9.5, 4.3, 6.7);
            float va[8] attribute ((aligned(32)));
            mm256 store ps(va, a);
Esempio
             m256 b = mm256 set ps(2.1, 5.2, 3.1, 1.9, 7.3, 9.5, 4.3, 6.7);
            float vu[8];
            mm256 storeu ps(vu, b);
```

```
m128d \rightarrow double[2] all.
void mm_storeu_pd(double* mem_addr, __m128d a)
                                                             m128d \rightarrow double[2]
                                                             movapd m128, xmm
Opzione gcc | -msse2
                                     Istruzione
                                                             movupd m128, xmm
            Copia l'oggetto a nell'array di 2 double all'indirizzo di memoria mem addr. La versione
Descrizione
            mm store pd richiede che mem addr sia allineato a un multiplo di 16 byte.
             m128d a = mm set pd(2.1, 5.2);
            double va[2] attribute ((aligned(16)));
            mm store pd(va, a);
Esempio
             m128d b = mm set pd(2.1, 5.2);
            double vu[2];
            mm storeu pd(vu, b);
```

```
void _mm256_store_pd (double* mem_addr, __m256d a)
                                                              m256d \rightarrow double[4] all.
m256d \rightarrow double[4]
                                                             vmovapd m256, ymm
                                    Istruzione
Opzione gcc
            -mavx
                                                             vmovupd m256, ymm
            Copia l'oggetto a nell'array di 4 double all'indirizzo di memoria mem addr. La versione
Descrizione
            mm256 store ps richiede che mem addr sia allineato a un multiplo di 32 byte.
             m256d a = mm256 set pd(2.1, 5.2, 3.1, 1.9);
            double va[4] attribute ((aligned(32)));
Esempio
            mm256 store pd(va, a);
            m256d b = mm256 set pd(2.1, 5.2, 3.1, 1.9);
```

```
double vu[4];
_mm256_storeu_pd(vu, b);
```

# 2.4 Operazioni aritmetiche

#### 2.4.1 Addizione e sottrazione

Le operazioni di sottrazione sono del tutto analoghe alle seguenti, rimpiazzando add con sub.

```
m128i mm add epi8 ( m128i a,  m128i b)
__m128i _mm_add_epi16(__m128i a, __m128i b)
                                                                 __m128i + m128i
__m128i _mm_add_epi32(__m128i a, __m128i b)
__m128i _mm_add_epi64(__m128i a, __m128i b)
                                                                 paddb xmm, xmm
                                                                paddw xmm, xmm
Opzione gcc | -msse2
                                       Istruzione
                                                                paddd xmm, xmm
                                                                paddq xmm, xmm
             Calcola a+b come vettori di char (epi3), short (epi16), int (epi32), oppure long
Descrizione
             (epi64) e restituisce il risultato.
              _{m128i \ a = \_mm\_set\_epi32(4, 3, 2, 1);}
              _{m128i} b = _{mm} set_{epi32}(1, 2, 3, 4);
Esempio
             __m128i c = _mm_add_epi32(a,b); // c = [5, 5, 5, 5]
```

| m256i <b>_mm</b><br>m256i <b>_mm</b> | 256_add_epi8 (m256i a,<br>256_add_epi16(m256i a,<br>256_add_epi32(m256i a,<br>256_add_epi64(m256i a, | m256i b)<br>m256i b)   | m256i +m256i  |
|--------------------------------------|--|--|---|
| Opzione gcc                          | -mavx2   | Istruzione   | vpaddb ymm, ymm, ymm vpaddw ymm, ymm, ymm vpaddd ymm, ymm, ymm vpaddq ymm, ymm, ymm |
| Descrizione                          | Calcola a+b come vettori di<br>(epi64) e restituisce il risultato                                    | char (epi8), short (epi16),  | int (epi32), oppure long  |
| Esempio                              | m256i b = mm256 set  | epi32(1, 2, 3, 4, 5, 6, epi32(8, 7, 6, 5, 4, 3, epi32(a,b); // c = [5, | 2, 1);  |

| m128 <b>_mm</b> | add_ps(m128 a,m128 :  | b)         | m128 +m128     |
|-----------------|---|------------|----------------|
| Opzione gcc     | -msse   | Istruzione | addps xmm, xmm |
| Descrizione     | Calcola a+b come vettori di float e restituisce il risultato. |            |                |

```
Esempio

__m128 a = _mm_set_ps(4.0, 3.0, 2.0, 1.0);
__m128 b = _mm_set_ps(1.0, 2.0, 3.0, 4.0);
__m128 c = _mm_add_ps(a,b); // c = [5.0, 5.0, 5.0, 5.0]
```

| m256 <b>_mm2</b> | <b>56_add_ps</b> (m256 a,m2                                   | m256 +m256  |                      |  |
|------------------|---|---|----------------------|--|
| Opzione gcc      | -mavx   | Istruzione  | vaddps ymm, ymm, ymm |  |
| Descrizione      | Calcola a+b come vettori di float e restituisce il risultato. |   |                      |  |
| Esempio          | $_{\rm m256}$ b = $_{\rm mm256\_set\_p}$                      | s(4.0, 3.0, 2.0, 1.0, 4.0)<br>s(1.0, 2.0, 3.0, 4.0, 1.0)<br>s(a,b); // $c = [5.0, 1.0]$ | 0, 2.0, 3.0, 4.0);   |  |

| m256d _ <b>mm256_add_pd</b> (m256d a,m256d b)m256d +m256d |   |  |                      |  |
|---|---|--|----------------------|--|
| Opzione gcc   | -mavx   | Istruzione   | vaddpd ymm, ymm, ymm |  |
| Descrizione   | Calcola a+b come vettori di double e restituisce il risultato.          |  |                      |  |
| Esempio   | m256d a = _mm256_set_<br>m256d b = _mm256_set_<br>m256d c = _mm256_add_ | pd(4.0, 3.0, 2.0, 1.0)<br>pd(1.0, 2.0, 3.0, 4.0)<br>pd(a,b); // c = [5 | ;                    |  |

## 2.4.2 Moltiplicazione

|  | _mullo_epi16(m128i a,<br>_mullo_epi32(m128i a, |            | m128i *m128i                    |
|--|--|------------|---------------------------------|
| Opzione gcc  | -msse2 (epi16)<br>-msse4.1 (epi32)             | Istruzione | pmullw xmm, xmm pmulld xmm, xmm |
| Moltiplica gli elementi corrispondenti in a e b come vettori di short (epi16) o int (epi32) e restituisce il risultato. Ciascun prodotto di valori a n bit è calcolato a 2n bit, prendendo i n bit meno significativi del risultato. |  |            |                                 |

```
__m128i a = _mm_set_epi32(4, 3, 2, 1);
__m128i b = _mm_set_epi32(1, 2, 3, 4);
__m128i c = _mm_mullo_epi32(a,b); // c = [4, 6, 6, 4]
```

```
__m256i __mm256_mullo_epi32(__m256i a, __m256i b) __m256i * __m256i * __m256i __mm256i __mm256_mullo_epi32(__m256i a, __m256i b) __m256i * __m256i * __m256i _
```

Per altre versioni delle operazioni di moltiplicazione, come quelle in virgola mobile, si rimanda a [IntelIntr].

#### 2.4.2 Minimo e massimo

Le operazioni di minimo sono del tutto analoghe a quelle che seguono, rimpiazzando max con min.

```
__m128i _mm_max_epi8 (__m128i a, __m128i b)
__m128i _mm_max_epi16(__m128i a, __m128i b)
m128i _mm_max_epi32( m128i a, m128i b)
                                                                max( m128i, m128i)
m128i mm max epu8 ( m128i a, __m128i b)
__m128i _mm_max_epu16(__m128i a, __m128i b)
m128i _mm_max_epu32( m128i a, m128i b)
                                                                  pmaxsb xmm, xmm
                                                                  pmaxsw xmm, xmm
             -msse4.1
                                                                  pmaxsd xmm, xmm
                                       Istruzione
Opzione gcc
             -msse2 (epu8, epi16)
                                                                  pmaxub xmm, xmm
                                                                  pmaxuw xmm, xmm
                                                                  pmaxud xmm, xmm
             Calcola il massimo degli elementi corrispondenti in a e b come vettori di char (epi8), short
Descrizione
             (epi16), int (epi32), unsigned char (epu8), unsigned short (epu16), unsigned
             int (epu32), e restituisce il risultato.
              m128i a = mm set epi32(4, -3, 2, -1);
             _{m128i} b = _{mm_set_epi32(1, 2, 3, -4);}
Esempio
             _{\text{m128i c}} = _{\text{mm}} = _{\text{max}} = _{\text{pi32}} (a,b); // c = [4, 2, 3, -1]
                                                   // d = [4, -3, 3, -1]
             m128i d = mm max epu32(a,b);
```

```
m256i _mm256_max_epi8 ( m256i a, m256i b)
m256i _mm256_max_epi16( m256i a, m256i b)
__m256i _mm256_max_epi32(__m256i a, __m256i b)
                                                         max( m256i, m256i)
__m256i _mm256_max_epu8 (__m256i a, __m256i b)
__m256i _mm256_max_epu16( m256i a, m256i b)
m256i mm256 max epu32 ( m256i a, m256i b)
                                                          vpmaxsb ymm, ymm, ymm
                                                          vpmaxsw ymm, ymm, ymm
                                                          vpmaxsd ymm, ymm, ymm
Opzione gcc | -mavx2
                                   Istruzione
                                                          vpmaxub ymm, ymm, ymm
                                                          vpmaxuw ymm, ymm, ymm
                                                          vpmaxud ymm, ymm, ymm
           Calcola il massimo degli elementi corrispondenti in a e b come vettori di char (epi8), short
Descrizione
           (epi16), int (epi32), unsigned char (epu8), unsigned short (epu16), unsigned
           int (epu32), e restituisce il risultato.
             m256i a = mm256 set epi32(4, -3, 2, -1, 4, -3, 2, -1);
           _{m256i} b = _{mm256} set _{epi32}(1, 2, 3, -4, 1, 2, 3, -4);
Esempio
```

Per altre operazioni si rimanda a [IntelIntr].

#### 2.5 Tabella riassuntiva

Riassumiamo nella seguente tabella le operazioni viste nei paragrafi precedenti:

| Copia da memoria a vettore (load)  |  |  |  |  |
|--|--|--|--|--|
| m128i _mm_load_si128 (m128i const* mem_addr)m128i _mm_loadu_si128(m128i const* mem_addr)           | array interi all. →m128i<br>array interi →m128i                    |  |  |  |
| m256i _mm256_load_si256 (m256i const* mem_addr)<br>m256i _mm256_loadu_si256(m256i const* mem_addr) | array interi all. →m256i<br>array interi →m256i                    |  |  |  |
| m128 _mm_load_ps (float const* mem_addr)m128 _mm_loadu_ps(float const* mem_addr)                   | float[4] allin. $\rightarrow$ m128<br>float[4] $\rightarrow$ m128  |  |  |  |
| m128d _mm_load_pd (double const* mem_addr)m128d _mm_loadu_pd(double const* mem_addr)               | double[2] allin. $\rightarrow$ m128d double[2] $\rightarrow$ m128d |  |  |  |

```
__m256 _mm256_load_ps (float const* mem addr)
                                                     float[8] allin. \rightarrow m256
__m256 _mm256_loadu_ps(float const* mem addr)
                                                     float[8] \rightarrow m256
m256d mm256 load pd (double const* mem addr)
                                                    double [4] allin. \rightarrow m256d
                                                    double[4] \rightarrow m256d
m256d _mm256_loadu_pd(double const* mem addr)
Copia da vettore a memoria (store)
                                                     _{\rm m128i} \rightarrow {\rm array\ interi\ allin}.
void _mm_store_si128 ( m128i* mem addr, m128i a)
                                                    _{\rm m128i} \rightarrow {\rm array\ interi}
void mm storeu si128( m128i* mem addr,  m128i a)
                                                    \underline{\hspace{0.3cm}} m256i \rightarrow array interi allin.
void mm256 store si256 ( m256i* mem addr,  m256i a)
                                                     m256i → array interi
void _mm256_storeu_si256( m256i* mem addr, m256i a)
m128 \rightarrow float[4] allin.
m128 \rightarrow float[4]
                                                     m256 \rightarrow float[8] allin.
m256 \rightarrow float[8]
                                                    \_m128d \rightarrow double[2] allin.
m128d \rightarrow double[2]
m256d \rightarrow double[4] allin.
m256d \rightarrow double[4]
Addizione
m128i _mm_add_epi8 ( m128i a, m128i b)
                                                     char[16] + char[16]
__m128i _mm_add_epi16(__m128i a, __m128i b)
                                                     short[8] + short[8]
__m128i _mm_add_epi32(__m128i a, __m128i b)
                                                      int[4] + int[4]
m128i _mm_add_epi64( m128i a, m128i b)
                                                      long[2] + long[2]
m256i _mm256_add_epi8 ( m256i a, m256i b)
                                                     char[32] + char[32]
__m256i _mm256_add_epi16(__m256i a, __m256i b)
                                                    short[16] + short[16]
__m256i _mm256_add_epi32(__m256i a, __m256i b)
                                                      int[8] + int[8]
__m256i _mm256_add_epi64( m256i a, m256i b)
                                                     long[4] + long[4]
m128 _mm_add_ps( m128 a, m128 b)
                                                     float[4] + float[4]
m128d _mm_add pd( m128d a, m128d b)
                                                     double[2] + double[2]
__m256 _mm256_add_ps(__m256 a, m256 b)
                                                     float[8] + float[8]
__m256d _mm256_add_pd(__m256d a, m256d b)
                                                     double[4] + double[4]
Prodotto
__m128i _mm_mullo_epi16(__m128i a, __m128i b)
                                                      short[8] * short[8]
__m128i _mm_mullo_epi32(__m128i a, __m128i b)
                                                      int[4] * int[4]
__m256i _mm256_mullo_epi16( m256i a, m256i b)
                                                     short[16] * short[16]
m256i _mm256_mullo_epi32( m256i a, m256i b)
                                                      int[8] * int[8]
```

| Massimo   |   |
|---|---|
| m128i mm max epi8 ( m128i a,  m128i b) m128i mm max epi16 ( m128i a,  m128i b) m128i mm max epi32 ( m128i a,  m128i b) m128i mm max epu8 ( m128i a,  m128i b) m128i mm max epu16 ( m128i a,  m128i b) m128i mm max epu32 ( m128i a,  m128i b)   | <pre>max(char[16]) max(short[8]) max(int[4]) max(unsigned char[16]) max(unsigned short[8]) max(unsigned int[4])</pre>   |
| m256i mm256 max epi8 ( m256i a, m256i b) m256i mm256 max epi16 ( m256i a, m256i b) m256i mm256 max epi32 ( m256i a, m256i b) m256i mm256 max epu8 ( m256i a, m256i b) m256i mm256 max epu16 ( m256i a, m256i b) m256i mm256 max epu16 ( m256i a, m256i b) m256i mm256 max epu32 ( m256i a, m256i b) | <pre>max(char[32]) max(short[16]) max(int[8]) max(unsigned char[32]) max(unsigned short[16]) max(unsigned int[8])</pre> |

## 2.5 Esempi

#### 2.5.1 Somma vettoriale di array di dimensione arbitraria

Si vuole realizzare una funzione che, dati tre array A, B e C di float di dimensione n, calcola la somma vettoriale C=A+B utilizzando istruzioni AVX. Partiamo da una semplice versione sequenziale e vediamo come vettorizzarla:

```
void somma_float(const float* A, const float* B, float* C, size_t n) {
   long i;
   for (i=0; i<n; i++) C[i] = A[i] + B[i];
}</pre>
```

Usando istruzioni AVX, possiamo effettuare somme di 8 float alla volta impaccati in oggetti vettoriali di tipo \_\_m256. Partiamo con una trasformazione del codice chiamata **loop unrolling** parziale di ragione k, che consiste nel ridurre di un fattore k il numero di iterazioni effettuando k operazioni per iterazione:

Osserviamo che, se n non è divisibile per 8, non è possibile effettuare tutte le somme a 8 a 8. Un secondo ciclo effettua quindi le somme rimanenti, che sono al più 7.

Rimpiazziamo ora il corpo del primo ciclo con istruzioni vettoriali che effettuano la somma:

```
#include <immintrin.h>
void somma_float(const float* A, const float* B, float* C, size_t n) {
   long i;
```

Possiamo testare il programma con un semplice main di prova:

```
int main() {
   long i;
   float A[17] = { 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17 };
   float B[17] = { 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17 };
   float C[17];
   somma_float((const float*)A, (const float*)B, C, 17);
   for (i=0; i<17; i++) printf("%f ", C[i]); // stampa 2 4 6 8 10 12 ...
   printf("\n");
}</pre>
```

Si noti che tutte le operazioni vettoriali utilizzate usano istruzioni AVX, pertanto possiamo usare l'opzione -mavx. Compiliamo con gcc somma\_float.c -o somma\_float -O1 -mavx ed eseguiamo con ./somma float.

#### Approfondimento.

E' interessante analizzare il codice assembly generato con gcc somma\_float.c -S -O1 -mavx (gcc versione 4.8.4 in Ubuntu). Il codice del loop vettorizzato è:

```
.L15:

vmovups (%rdi,%rax), %ymm1
vmovups (%rsi,%rax), %ymm0
vaddps %ymm0, %ymm1, %ymm0
vmovups %ymm0, (%rdx,%rax)
addq $8, %r8
addq $32, %rax
cmpq %r9, %r8
jne .L15
```

dove %rdi è A, %rsi è B, %rdx è C, %r8 è i ed %r9 è n.

### 2.5.2 Prodotto scalare di array di dimensione arbitraria

Si vuole realizzare una funzione che, dati due array A, B di int di dimensione n, calcola il prodotto scalare s=A·B utilizzando istruzioni AVX. Partiamo da una semplice versione sequenziale e vediamo come vettorizzarla:

```
int prods_int(const int* A, const int* B, size_t n) {
   long i;
   int s = 0;
   for (i=0; i<n; i++) s += A[i] * B[i];
   return s;
}</pre>
```

Usando istruzioni AVX, Procediamo con il loop unrolling come mostrato nel paragrafo 2.5.1:

La costruzione mostrata usa un vettore di appoggio di  $8 \, {\rm int}$  per calcolare le somme parziali, dove  $s \, [\, 0\, ]$  contiene le somme dei prodotti degli elementi di  $A \, e \, B$  con indice i tale che i  $\% \, 8 == 0$ ,  $s \, [\, 1\, ]$  quelle degli elementi con i  $\% \, 8 == 1$ , ecc. Gli elementi rimanenti considerati nel secondo ciclo vengono accumulati in  $s \, [\, 0\, ]$ .

Così formulato, il codice si vettorizza direttamente come segue:

```
#include <immintrin.h>
int prods int(const int* A, const int* B, size t n) {
   long i;
   int s[8] attribute ((aligned(32))) = { 0 };
   m256i a, b, c, d = mm256 load si256((const m256i*)s); // copia s in d
   for (i=0; i+7 < n; i+=8) { // loop unrolling di ragione 8
       a = mm256 loadu si256((const m256i*)(A+i)); // copia A[i..i+7] in a
       b = mm256 loadu si256((const m256i*)(B+i)); // copia B[i..i+7] in b
       c = mm256 mullo epi32(a,b);
                                                     // c=a*b
                                                     // d=d+c
       d = mm256 \text{ add epi32(c,d);}
                                               // copia d in s
    mm256 store si256(( m256i*)s, d);
   for (; i < n; i++) s[0] += A[i] * B[i];
   return s[0]+s[1]+s[2]+s[3]+s[4]+s[5]+s[6]+s[7];
```

Poiché non abbiamo alcuna garanzia che gli array A e B siano allineati a indirizzi multipli di 32, dobbiamo utilizzare istruzioni load che non richiedono allineamento (\_mm256\_loadu\_si256). Allineiamo invece l'array s usando la direttiva \_\_attribute\_\_((aligned(32))), così possiamo usare la \_mm256\_load\_si256 che richiede allineamento².

Per un test, possiamo usare il seguente semplice programma di prova:

```
int main() {
   int A[17] = { 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17 };
   int B[17] = { 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17 };

   int s = prods_int((const int*)A, (const int*)B, 17);

   printf("%d\n", s); // stampa 1785
   return 0;
}
```

Poiché l'operazione \_mm256\_mullo\_epi32 è disponibile solo in AVX2, compiliamo con gcc prods int.c -01 -mavx2 -o prods int.

<sup>&</sup>lt;sup>2</sup> La cosa è tuttavia praticamente irrilevante a livello prestazionale, poiché la load da s è esterna al ciclo.

# Bibliografia

[IntelIntr] The Intel Intrinsics Guide <a href="https://software.intel.com/sites/landingpage/IntrinsicsGuide/">https://software.intel.com/sites/landingpage/IntrinsicsGuide/</a> (verificato 5 gennaio 2016)

[PosixMemalign] The Open Group Base Specifications Issue 7, posix\_memalign http://pubs.opengroup.org/onlinepubs/9699919799/functions/posix\_memalign.html (verificato 5 gennaio 2016)

[GNUMemalign] The GNU standard library: Allocating Aligned Memory Blocks <a href="http://www.gnu.org/software/libc/manual/html\_node/Aligned-Memory-Blocks.html">http://www.gnu.org/software/libc/manual/html\_node/Aligned-Memory-Blocks.html</a> (verificato 5 gennaio 2016)